

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HCM
KHOA CÔNG NGHỆ THÔNG TIN**



ĐỀ CƯƠNG TIỂU LUẬN CUỐI KHÓA

MÃ MÔN HỌC: AIOT331185_01CLC

**TỔNG HỢP DỮ LIỆU GIA TỐC BA TRỤC
CÓ ĐIỀU KIỆN THEO HOẠT ĐỘNG BẰNG 1D-cVAE
VÀ ĐÁNH GIÁ TSTR TRÊN PPG-DaLiA**

Giảng viên hướng dẫn: ThS. Hồ Nhật Minh

Sinh viên thực hiện: Nguyễn Bách Tùng
Mã số sinh viên: 23110166

Phạm vi: dữ liệu gia tốc cổ tay, tám hoạt động,
đánh giá trên người tham gia không thuộc tập huấn luyện.

Tp. Hồ Chí Minh, tháng 09 năm 2026

1. ĐẶT VẤN ĐỀ VÀ MỤC TIÊU

1.1. Bối cảnh kỹ thuật và tính cấp thiết

Nhận dạng hoạt động người dùng (Human Activity Recognition – HAR) từ gia tốc cổ tay là một bài toán trong hệ thống IoT và thiết bị đeo. Đề tài sử dụng dữ liệu gia tốc của PPG-DaLiA để khảo sát khả năng tổng hợp dữ liệu theo nhãn hoạt động bằng mô hình tự mã hóa biến phân có điều kiện một chiều (1D-cVAE). Giá trị nghiên cứu được xác định bằng tính hữu ích của dữ liệu sinh đối với HAR, thay vì chỉ dựa vào hình dạng tín hiệu [1], [2], [5], [6].

1.2. Phát biểu bài toán và phạm vi

Mỗi đầu vào x là cửa sổ gia tốc đã chuẩn hóa, có kích thước 3×128 , tương ứng 4 giây tại 32 Hz; nhãn nội bộ y thuộc $\{0, \dots, 7\}$. Mô hình học $q_\phi(z|x, c)$ và decoder $g_\theta(z, c)$, với c là nhãn one-hot và z có 32 chiều. Sau huấn luyện, lấy z từ $N(0, I)$ và chọn c để sinh cửa sổ mới; không cần cung cấp một cửa sổ thật cho bước sinh.

Huấn luyện và tạo dữ liệu thực hiện ngoại tuyến trên máy tính. Đề tài không tạo sinh PPG, không ước lượng nhịp tim và không mặc định triển khai cVAE trên vi điều khiển. Số tham số, kích thước trọng số và độ trễ chỉ được công bố khi đã đo, kèm môi trường đo; chưa suy diễn thành kết luận về RAM/Flash hay thời gian thực trên thiết bị đeo.

1.3. Mục tiêu và câu hỏi thực nghiệm

Câu hỏi 1: Bộ phân loại học từ dữ liệu sinh đạt hiệu năng như thế nào so với bộ phân loại học từ dữ liệu thật trên cùng người kiểm thử? Câu hỏi 2: Bổ sung dữ liệu cVAE có cải thiện Macro-F1 và các lớp ít mẫu so với dữ liệu thật, lấy mẫu lặp và tăng cường truyền thống hay không?

Mục tiêu là xây dựng quy trình tái lập được; báo cáo hiệu năng theo người, theo lớp, khoảng cách TSTR–TRTR và đặc trưng phân phối/phổ. Đánh giá dựa trên mức tham chiếu thực nghiệm và các đối chứng cùng điều kiện, không dựa trên ngưỡng chất lượng chưa có cơ sở. Kết quả không cải thiện vẫn được báo cáo và phân tích.

2. TẬP DỮ LIỆU VÀ TIỀN XỬ LÝ

2.1. Đặc tả dữ liệu và nhãn

PPG-DaLiA gồm 15 người tham gia S1–S15. Sử dụng trường signal/wrist/ACC, tần số 32 Hz [1]. Theo mã xử lý công bố ở [3], trường activity có tần số 4 Hz; trường label chứa nhịp tim, không phải nhãn HAR. Bảng dưới phân biệt mã nguồn với mã nội bộ; khi triển khai phải đối chiếu lại readme và tệp thực nhận.

Mã gốc → nội bộ	Hoạt động	Mã gốc → nội bộ	Hoạt động
1 → 0	Sitting – ngồi	5 → 4	Driving – lái xe
2 → 1	Stairs – cầu thang	6 → 5	Lunch break – nghỉ trưa
3 → 2	Table soccer – bi lắc	7 → 6	Walking – đi bộ
4 → 3	Cycling – đạp xe	8 → 7	Working – làm việc

Mã gốc 0 (no activity) được loại khỏi bài toán tám lớp. Chỉ đổi $y = \text{mã_gốc} - 1$ sau khi xác nhận mã thuộc 1–8. Số lượng và tỷ lệ lớp được thống kê từ cửa sổ hợp lệ sau tiền xử lý, theo từng người và từng tập dữ liệu.

2.2. Quy trình tiền xử lý và đóng gói tensor

Đồng bộ nhãn: giữ nguyên trục thời gian của từng người. Với dữ liệu đã đồng bộ cùng mốc bắt đầu, mẫu ACC thứ i nhận nhãn $\text{activity}[\text{floor}(i/8)]$ (chỉ số từ 0); tương đương giữ nhãn bậc không từ 4 Hz lên 32 Hz. Phải kiểm tra mốc thời gian và độ dài trước khi áp dụng; không nội suy tuyến tính nhãn rời rạc [1], [3].

Cửa sổ: chiều dài 128 mẫu, bước 64 mẫu, chồng lấn 50%. Chỉ giữ cửa sổ đủ mẫu, hữu hạn và có duy nhất một nhãn gốc hợp lệ trong toàn cửa sổ. Cửa sổ có mã 0 hoặc trộn hoạt động bị loại và ghi số lượng theo người/lớp. Không xóa đoạn rồi nối hai khoảng thời gian rời nhau trước khi chia cửa sổ.

Xử lý tín hiệu: cấu hình chính giữ ba trục và thành phần một chiều; không áp dụng lọc thông cao 0,5 Hz hoặc trừ trung bình từng cửa sổ. Đây là lựa chọn để không loại bỏ trước thông tin tư thế/biên độ tĩnh. Khảo sát bộ lọc, nếu có, là thí nghiệm riêng dùng cùng cấu hình cho các nhánh so sánh.

Chuẩn hóa: tính trung bình μ và độ lệch chuẩn σ của mỗi trục r chỉ từ mẫu hợp lệ thuộc các người train, mỗi thời điểm tính một lần. Dùng $x = (a - \mu_r)/\max(\sigma_r, 10^{-8})$ cho train, validation và test; lưu scaler để tái sử dụng [9]. Không ước lượng lại scaler theo từng người validation/test. Decoder sinh trực tiếp trong không gian chuẩn hóa này; không chuẩn hóa dữ liệu sinh thêm lần nữa.

Đóng gói: tín hiệu float32 có dạng (B,3,128), nhãn int64 có dạng (B,), kèm subject_id và chỉ số bắt đầu cửa sổ. One-hot chỉ được tạo khi đưa nhãn vào cVAE; không cung cấp nhãn thật làm đầu vào của bộ phân loại HAR.

2.3. Chiến lược chia dữ liệu theo người tham gia

Phân chia theo người tham gia: train S1–S11; validation S12–S13; test S14–S15. Chia người trước mọi bước học tham số tiền xử lý hoặc mô hình. Validation phục vụ chọn cấu hình và dừng sớm; test chỉ dùng đánh giá sau khi khóa toàn bộ quy trình. Không chọn tỷ lệ sinh hay ngưỡng lọc dựa trên test.

Đây là một phép chia hold-out theo người do đề tài lựa chọn, không phải benchmark chính thức. Với hai người test, kết luận chỉ có tính thăm dò trên phép chia này. Báo cáo từng người và trung bình đều theo người; nhiều seed không thay thế được việc kiểm tra trên nhiều người.

3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Kiến trúc 1D-cVAE

Khối	Cấu hình và kích thước đầu ra
Đầu vào	Ghép x và c mở rộng theo thời gian: (B,11,128).
Encoder	4 Conv1d: $k=5, s=2, p=2$; kênh $32 \rightarrow 64 \rightarrow 128 \rightarrow 256$; chiều dài $64 \rightarrow 32 \rightarrow 16 \rightarrow 8$. BatchNorm + LeakyReLU(0,2).
Không gian ẩn	Flatten 2048; hai Linear độc lập $2048 \rightarrow 32$ cho μ và log-variance; z có dạng (B,32).
Chiều decoder	Ghép $[z;c]$: (B,40); Linear $40 \rightarrow 2048$; reshape (B,256,8).
Giải mã	Đúng 4 ConvTranspose1d: $256 \rightarrow 128 \rightarrow 64 \rightarrow 32 \rightarrow 3$; $k=5, s=2, p=2, \text{output_padding}=1, \text{dilation}=1$. Chiều dài $16 \rightarrow 32 \rightarrow 64 \rightarrow 128$.
Đầu ra	Ba khối decoder đầu: BatchNorm + LeakyReLU; khối cuối tuyến tính, không BatchNorm/Tanh/Sigmoid; $\hat{x}$: (B,3,128).

Với cấu hình trên, $\text{Lout} = 2\text{Lin} - 1 + \text{output_padding} = 2\text{Lin}$ [8]. Mã nguồn phải kiểm tra hình dạng tensor bằng dữ liệu giả trước khi huấn luyện.

3.2. Điều kiện hóa và cơ chế sinh dữ liệu

Encoder nhận tín hiệu và nhãn one-hot; decoder nhận z và cùng nhãn. Đặt $\ell = \log(\sigma^2)$, lấy $z = \mu + \exp(\ell/2) \odot \varepsilon$ với $\varepsilon \sim N(0, I)$ để huấn luyện [4], [5]. Khi tạo tập synthetic, chuyển mô hình sang chế độ eval, lấy z độc lập từ prior $N(0, I)$, chọn nhãn theo kế hoạch và dùng đầu ra $g_\theta(z, c)$. Không thêm nhiễu quan sát vào đầu ra decoder trong cấu hình chính.

Tái tạo từ posterior chỉ dùng theo dõi học mô hình; không gọi các bản tái tạo là mẫu sinh độc lập để thay thế TSTR. Tuyệt đối không mã hóa tín hiệu validation/test rồi dùng bản tái tạo làm dữ liệu huấn luyện bộ phân loại.

3.3. Hàm mất mát

Với prior chuẩn tắc, biên dưới biến phân có điều kiện được viết [4], [5]:

$$\text{ELBO}(x, c) = \mathbb{E}_{q_\phi(z|x, c)}[\log p_\theta(x | z, c)] - D_{\text{KL}}(q_\phi(z | x, c) \parallel \mathcal{N}(0, I)).$$

Trong một batch B , dùng sai số tái tạo trung bình trên $D=384$ phần tử và KL cộng trên các chiều ẩn:

$$\begin{aligned} \mathcal{L}_{\text{rec}} &= \frac{1}{BD} \sum_{i=1}^B \|x_i - \hat{x}_i\|_2^2, \quad D = 3L = 384. \\ \mathcal{L}_{\text{KL}} &= -\frac{1}{2B} \sum_{i=1}^B \sum_{j=1}^{d_z} \left(1 + \ell_{ij} - \mu_{ij}^2 - \exp(\ell_{ij})\right). \\ \mathcal{L}_t &= \frac{1}{2} \mathcal{L}_{\text{rec}} + \frac{\beta_t}{D} \mathcal{L}_{\text{KL}}, \quad \beta_t = \beta_{\max} \min(t/25, 1). \end{aligned}$$

Cấu hình chính $\beta_{\max}=1$; t là số epoch đã hoàn thành, bắt đầu từ 0. Với likelihood Gaussian có phương sai cố định bằng 1 trong không gian chuẩn hóa, tại $\beta=1$, hàm trên bằng negative ELBO chia D , bỏ hằng số. Trong giai đoạn tăng β , đây là mục tiêu có trọng số, không gọi là ELBO chuẩn. Cách chia trung bình phải thống nhất trong code; không thay KL/D bằng KL/dz mà giữ nguyên β .

Lưu riêng reconstruction loss, KL và tổng loss. Tăng β không bảo đảm tránh posterior collapse; cần kiểm tra độ đa dạng khi thay z ở cùng một nhãn. $\beta_{\max}=0,1$ chỉ là cấu hình khảo sát bổ sung nếu tài nguyên cho phép, không phải yêu cầu quét lưới.

3.4. Bộ phân loại và mô hình đối chứng

Dùng một kiến trúc HAR cố định cho tất cả nguồn dữ liệu: 3 khối Conv1d (32,64,128 kênh; $k=5$, $s=1$, $p=2$), mỗi khối ReLU và MaxPool1d(2), sau đó Global Average Pooling và Linear(128,8). Huấn luyện bằng cross-entropy không trọng số; không dùng chung encoder/trọng số với cVAE. TRTR là mức tham chiếu thực nghiệm, không phải trần hiệu năng lý thuyết.

4. THIẾT KẾ THỰC NGHIỆM VÀ CHỈ SỐ

4.1. Môi trường, tối ưu hóa và chọn mô hình

Dùng Python/PyTorch; ghi phiên bản thực cài, hệ điều hành, CPU/GPU và CUDA tương ứng trong requirements và log. Cấu hình khởi đầu: AdamW, learning rate 10^{-3} , weight decay 10^{-4} , batch size 64; cVAE tối đa 100 epoch, CosineAnnealingLR với $T_{\max}=100$ và learning rate tối thiểu 10^{-5} .

Checkpoint cVAE được chọn bằng validation loss tính với $\beta=1$ cố định; cố định nhiều lấy mẫu validation để giảm dao động. Early stopping chỉ bắt đầu sau 25 epoch, patience=15. Bộ phân loại chọn checkpoint bằng Macro-F1 trung bình đều theo người validation; cùng ngân sách cập nhật tối đa, batch size và quy tắc dừng sớm cho mọi nhánh, đồng thời báo cáo số bước thực tế.

Khóa cấu hình trên validation, rồi chạy các nhánh chính với ba seed 2026, 2027, 2028. Ghép seed tương ứng giữa các đối chứng; lưu riêng seed khởi tạo cVAE, sinh dữ liệu và bộ phân loại. Không chọn seed tốt nhất để báo cáo.

4.2. Bộ chỉ số và nguyên tắc diễn giải

Tính hữu ích: TSTR (Train on Synthetic, Test on Real) là quy trình đánh giá downstream, không tự nó là kiểm định giả thuyết thống kê [6]. cVAE chỉ học từ train thật; bộ phân loại TSTR chỉ cập nhật trọng số bằng dữ liệu sinh. Đề tài vẫn sử dụng validation thật để chọn checkpoint và phải công bố rõ điều này, không gọi toàn quy trình là “không dùng dữ liệu thật”.

Chỉ số chính: Macro-F1 tám lớp của từng người test, sau đó lấy trung bình đều theo người. Báo cáo thêm Accuracy, F1 từng lớp, số mẫu mỗi lớp và confusion matrix; kết quả gộp cửa sổ chỉ là bổ sung. Quy định zero_division=0 và công bố lớp vắng mặt; không âm thầm loại lớp khó khỏi trung bình. Gọi F là Macro-F1 trung bình theo người:

$$\Delta_{\text{TSTR}} = F_{\text{TRTR}} - F_{\text{TSTR}}, \quad G_{\text{aug}} = F_{\text{Real+cVAE}} - F_{\text{Real}}.$$

Giữ dấu của các chênh lệch. Δ_{TSTR} dương thể hiện mức giảm so với TRTR; G_{aug} dương thể hiện mức tăng của nhánh bổ sung cVAE. Khi trình bày F1 trên thang phần trăm, chênh lệch được ghi bằng điểm phần trăm, không nhầm với phần trăm tương đối.

Khoảng cách phân phối MMD² [7]: tính riêng từng lớp, rồi lấy trung bình đều tám lớp. Dùng estimator có độ chệch (bao gồm đường chéo) và kernel RBF đa băng thông. Đặc trưng cố định gồm mean, standard deviation và RMS của từng trục (9 chiều), ghép log(PSD+10⁻⁸) của ba trục (99 chiều), tổng 108 chiều. Không dùng encoder cVAE làm thước đo duy nhất.

Ước lượng PSD bằng Welch [10]: fs=32 Hz, cửa sổ Hann tuần hoàn, nperseg=64, noverlap=32, nfft=64, detrend=False, scaling="density", phổ một phía. Đây là lựa chọn phân tích 0,5 Hz/bin, không phải chứng cứ đủ để mô tả mọi động học hoạt động. Tín hiệu thật và sinh đều dùng cùng không gian chuẩn hóa.

Chuẩn hóa từng chiều đặc trưng bằng thống kê train thật. Băng thông cơ sở σ_0 là median khoảng cách Euclidean dương trên tối đa 2.000 cửa sổ train đã chọn bằng seed cố định; dùng các băng thông $\{0,5\sigma_0, \sigma_0, 2\sigma_0\}$. Khóa đặc trưng, scaler, kernel và số mẫu trước khi đánh giá test. Nếu không có khoảng cách dương, báo lỗi dữ liệu/đặc trưng thay vì đặt băng thông tùy ý.

Mỗi lớp dùng số lượng mẫu bằng nhau giữa các phép so sánh, tối đa 300, và cùng seed lấy mẫu. Báo cáo MMD²(real_test, synthetic) cùng mốc MMD²(real_test, real_train), với các tập real lấy cửa sổ không chồng lấn cho phân tích này. Không xem mốc real–real là cận dưới hay dùng một ngưỡng MMD cố định để tuyên bố “đạt chuẩn”.

Đặc trưng phổ và biên độ: với từng lớp/trục, so sánh phổ trung bình đã chuẩn hóa tổng công suất bằng khoảng cách L1; đồng thời báo cáo tổng công suất, trung bình và độ lệch chuẩn tín hiệu để không che mất sai khác biên độ. Khoảng cách phổ này là chỉ số mô tả; không tự xác nhận tính hữu ích của dữ liệu sinh. R², nếu khảo sát riêng, phải được gọi đúng là hệ số xác định [11].

Đa dạng và ghi nhớ: lấy nhiều z cho cùng nhãn; đối chiếu phân bố biên độ, biến thiên và khoảng cách đến cửa sổ train gần nhất. Dùng RMSE trên 384 phần tử chuẩn hóa; so sánh synthetic–train với real_test–train trên cùng tập ứng viên. Đây chỉ là phân tích chẩn đoán, không chứng minh riêng tư hay không sao chép.

Độ ổn định: công bố trung bình và độ lệch chuẩn qua ba seed, kèm số liệu từng người. Không xem cửa sổ chồng lấn là những người quan sát độc lập; không suy ra ý nghĩa thống kê quần thể từ hai người test. Không coi hình t-SNE, phổ trung bình hay reconstruction loss thấp là bằng chứng đủ cho dữ liệu sinh tốt.

4.3. Kịch bản đối chứng và phân tích thành phần

Nhánh	Dữ liệu cập nhật trọng số bộ phân loại	Mục đích
TRTR	Chỉ train thật	Mức tham chiếu
Real + ROS	Train thật + mẫu train được lấy lặt	Đối chứng tăng số mẫu
Real + truyền thống	Train thật + jittering/scaling	Đối chứng tăng cường đơn giản
TSTR	Chỉ mẫu prior-sampling từ cVAE	Khả năng thay thế dữ liệu train
Real + cVAE	Train thật + dữ liệu sinh có điều kiện	Lợi ích tăng cường dữ liệu

Trong TSTR chính, số mẫu sinh mỗi lớp bằng số cửa sổ train thật của lớp đó. Với ba nhánh tăng cường, lấy n^* là median số cửa sổ của tám lớp train, làm tròn lên; bổ sung $\max(0, n^* - n_c)$ mẫu cho lớp c. ROS, truyền thống và cVAE phải có cùng số mẫu bổ sung theo lớp; không xác định lớp hiếm từ test.

Đối chứng truyền thống khởi đầu bằng jitter Gaussian $\sigma=0,01$ và hệ số scaling chung cho ba trục lấy từ Uniform(0,95;1,05), áp dụng trong không gian chuẩn hóa. Đây là cấu hình đề xuất, phải kiểm tra tính hợp lý trên train/validation; không mặc định mọi phép biến đổi đều bảo toàn ngữ nghĩa. Cố định một cấu hình chung trước test.

Ưu tiên hoàn thành năm nhánh chính. Phân tích bổ sung chọn từng yếu tố: tăng β so với β cố định, hoặc huấn luyện cVAE bằng nhãn bị hoán vị để kiểm tra vai trò thông tin điều kiện. Không quét đồng thời nhiều β , nhiều dz và nhiều tỷ lệ sinh. VAE không điều kiện không được đưa thẳng vào TSTR có giám sát nếu chưa có cơ chế gán nhãn độc lập hợp lệ.

5. KẾ HOẠCH THỰC HIỆN VÀ BÀN GIAO

5.1. Tiến độ dự kiến trong bốn tuần

Thời gian	Công việc và điểm kiểm tra	Sản phẩm
Tuần 1	Đối chiếu tệp, nhãn và thời gian; khóa split; thống kê cửa sổ; xây dựng TRTR.	Manifest, scaler, mapping, baseline.
Tuần 2	Cài đặt cVAE; kiểm tra tensor/loss; huấn luyện; sinh từ prior và kiểm tra đa dạng.	Code, checkpoint phát triển, log.
Tuần 3	Chạy các đối chứng trên validation; chọn và khóa cấu hình; ưu tiên lặt các nhánh chính.	Cấu hình khóa, nhật ký chọn mô hình.
Tuần 4	Đánh giá test với các cấu hình/seed đã khóa; tổng hợp theo người/lớp; hoàn thiện báo cáo.	Bảng kết quả, hình, mã nguồn tái lập.

5.2. Danh mục sản phẩm và điều kiện hoàn thành

Bàn giao báo cáo kỹ thuật 15–25 trang, không yêu cầu slide; mã nguồn theo các khối data_loader, models_cvae, train_cvae, train_classifier, eval_tstr; README, requirements, cấu hình, bảng ánh xạ nhãn, danh sách split, scaler, thống kê cửa sổ loại/giữ, log và dự đoán trên test. Bàn giao checkpoint cvae_acc_dalia_best.pth và classifier_tstr_best.pth sau huấn luyện, kèm thông tin seed/cấu hình.

Điều kiện hoàn thành là pipeline chạy lại được, không trộn người giữa các tệp, dữ liệu sinh đúng kích thước, các đối chứng được so sánh công bằng và số liệu truy nguyên được. Nếu thiếu tài nguyên, giảm thí nghiệm bổ sung trước; không thay số đo bằng mục tiêu dự kiến. Nếu cVAE không cải thiện HAR, báo cáo đúng kết quả và giới hạn của phương pháp.

6. TÀI LIỆU THAM KHẢO

- [1] A. Reiss, I. Indlekofer và P. Schmidt, “PPG-DaLiA,” UCI Machine Learning Repository, 2019. DOI: 10.24432/C53890. [Nguồn trực tuyến](#)
- [2] A. Reiss, I. Indlekofer, P. Schmidt và K. Van Laerhoven, “Deep PPG: Large-Scale Heart Rate Estimation with Convolutional Neural Networks,” *Sensors*, tập 19, số 14, bài 3079, 2019. DOI: 10.3390/s19143079. [Nguồn trực tuyến](#)
- [3] P. H. Charlton, “collate_ppg_dalia_dataset.m,” mã nguồn xử lý PPG-DaLiA, kho resources. Đối chiếu trường activity, label, tần số nhẩn và bảng mã hoạt động; truy cập 22/09/2026. [Nguồn trực tuyến](#)
- [4] D. P. Kingma và M. Welling, “Auto-Encoding Variational Bayes,” arXiv:1312.6114, 2013. DOI: 10.48550/arXiv.1312.6114. [Nguồn trực tuyến](#)
- [5] K. Sohn, H. Lee và X. Yan, “Learning Structured Output Representation using Deep Conditional Generative Models,” *Advances in Neural Information Processing Systems* 28, 2015. [Nguồn trực tuyến](#)
- [6] C. Esteban, S. L. Hyland và G. Rätsch, “Real-valued (Medical) Time Series Generation with Recurrent Conditional GANs,” arXiv:1706.02633, 2017. DOI: 10.48550/arXiv.1706.02633. [Nguồn trực tuyến](#)
- [7] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf và A. Smola, “A Kernel Two-Sample Test,” *Journal of Machine Learning Research*, tập 13, tr. 723–773, 2012. [Nguồn trực tuyến](#)
- [8] PyTorch, “ConvTranspose1d,” tài liệu API chính thức. Đối chiếu công thức chiều dài đầu ra và output_padding; truy cập 22/09/2026. [Nguồn trực tuyến](#)
- [9] scikit-learn, “Common pitfalls and recommended practices,” tài liệu chính thức, mục tiền xử lý và rò rỉ dữ liệu; truy cập 22/09/2026. [Nguồn trực tuyến](#)
- [10] SciPy, “scipy.signal.welch,” tài liệu API chính thức về ước lượng mật độ phổ công suất; truy cập 22/09/2026. [Nguồn trực tuyến](#)
- [11] scikit-learn, “r2_score,” tài liệu API chính thức về hệ số xác định R^2 ; truy cập 22/09/2026. [Nguồn trực tuyến](#)

Các thông số kiến trúc, cửa sổ, phép chia người tham gia và lịch thực nghiệm trong đề cương là lựa chọn thiết kế của đề tài, không phải cấu hình chuẩn bắt buộc của các tài liệu trên. Tỷ lệ lớp và chỉ số hiệu năng phải được tính từ lần thực nghiệm thực tế.